

OncoTarget Mining: Priorización Computacional de Candidatos de Evasión Inmune mediante Minería Transversal de Datos Transcriptómicos Públicos

Un marco de aprendizaje automático supervisado integrando firmas scRNA-seq y repositorios genómicos públicos (ENA/NCBI/SRA)

OncoTarget Mining Pipeline • Bioinformática Computacional e Inmunogenómica

RESUMEN EJECUTIVO

Antecedentes: La disponibilidad creciente de datos transcriptómicos públicos ofrece una oportunidad para reutilizar información molecular y explorar hipótesis biológicas sobre resistencia inmune. No obstante, la heterogeneidad técnica entre estudios dificulta su explotación sistemática.

Objetivo: Desarrollar una pipeline computacional reproducible que combine análisis transcriptómico unicelular (scRNA-seq), aprendizaje automático supervisado (Random Forest) y minería transversal de datasets públicos para estratificar perfiles de respuesta inmune y priorizar candidatos moleculares de evasión.

Métodos: Se empleó un atlas de referencia PBMC 3k (2,638 células, 1,826 genes) [1] para extraer firmas citotóxicas (**NKG7**, **GZMA**, **CCL5**, **GNLY**, **PRF1**). Se entrenó un modelo Random Forest y se aplicó de forma remota a 46 muestras SRA/FASTQ de la cohorte principal PRJEB108071 (ENA/NCBI) [2, 3]. Las muestras clasificadas como inmunosupresoras fueron evaluadas mediante deltas de expresión sobre el panel **CD274**, **PDCD1**, **TIGIT**, **HAVCR2**.

Resultados: En PRJEB108071, 32/46 muestras (69.57%) mostraron Respuesta Moderada y 14/46 (30.43%) perfil Bajo/Inmunosupresor. Entre los candidatos, **CD274** presentó el único delta de expresión positivo ($\Delta = +0.042990$), en contraste con valores negativos para **PDCD1** (-0.209052), **TIGIT** (-0.229288) y **HAVCR2** (-0.503626).

Conclusión: La arquitectura demuestra la factibilidad de conectar scRNA-seq con minería bulk pública para priorizar objetivos terapéuticos. En la cohorte evaluada, **CD274 (PD-L1)** fue priorizado como el candidato principal para validación experimental posterior.

Palabras clave: scRNA-seq, Random Forest, inmunología computacional, evasión inmune, CD274, PD-L1, minería de datos, ENA/SRA.

1. Introducción

La caracterización de los mecanismos de evasión inmune constituye un desafío central en la oncología computacional. La respuesta inmunitaria antitumoral está condicionada no solo por la presencia de infiltrados celulares, sino por los estados funcionales microambientales y los ejes de señalización inhibitoria. Los repositorios públicos como el European Nucleotide Archive (ENA) [2] y el NCBI Sequence Read Archive (SRA) [3] albergan petabytes de datos transcriptómicos no explotados para preguntas biológicas secundarias. El marco *OncoTarget Mining* aborda las barreras de heterogeneidad mediante la conversión de perfiles heterogéneos en representaciones funcionales estandarizadas derivadas de transcriptómica unicelular.

2. Materiales y Métodos

2.1. Arquitectura del Flujo Computacional

El flujo de trabajo se estructura en tres capas independientes:

- **Capa de Referencia (scRNA-seq):** Procesamiento del atlas PBMC 3k (2,638 células, 1,826 genes) utilizando el ecosistema bioinformático de Scanpy y AnnData [4, 5] para cuantificar señales citotóxicas.

- **Capa de Clasificación (Machine Learning):** Entrenamiento y serialización de un modelo Random Forest implementado en Scikit-learn [6] e impulsado por Scikit-learn/Joblib, basado en marcadores efectores (*NKG7, GZMA, CCL5, GNLy, PRF1*).
- **Capa de Inferencia Transversal:** Recuperación programática de corridas SRA/FASTQ desde ENA/NCBI [2, 3], asignación de perfiles funcionales e inferencia de deltas de expresión.

2.2. Cohorte Analizada y Evaluación de Evasión

Se evaluó la cohorte principal **PRJEB108071** (46 corridas SRA/FASTQ) procedente de ENA/NCBI [2, 3]. Tras clasificar las muestras, la priorización de candidatos en el subgrupo de alta inmunosupresión se determinó mediante la diferencia media de expresión:

$$\Delta_Expresión = E_ (Baja / Inmunosupresora) - E_ (Respuesta Moderada)$$

3. Resultados

Tabla 1. Estratificación funcional de la cohorte PRJEB108071 y deltas de expresión para el panel de evasión inmune.

Categoría / Target	Muestras / Métrica	Proporción / Valor Delta	Interpretación Computacional
Respuesta Moderada	32 / 46	69.57%	Actividad citotóxica basal preservada
Baja / Inmunosupresora	14 / 46	30.43%	Subgrupo de alto riesgo inmune
CD274 (PD-L1)	Δ Expression	+0.042990	Priorizado (Sobreexpresado en inmunosupresión)
PDCD1 (PD-1)	Δ Expression	-0.209052	No priorizado (Infraexpresado)
TIGIT	Δ Expression	-0.229288	No priorizado (Infraexpresado)
HAVCR2 (TIM-3)	Δ Expression	-0.503626	No priorizado (Infraexpresado)

Aproximadamente 3 de cada 10 muestras (30.43%) mostraron un perfil compatible con evasión inmune. **CD274** fue el único miembro del panel con delta positivo, destacando al eje PD-L1 como el principal objetivo funcional en esta cohorte.

4. Discusión y Limitaciones

El hallazgo central radica en la capacidad de conectar scRNA-seq con repositorios bulk para identificar candidatos concretos. No obstante, deben considerarse limitaciones críticas:

- **Transferencia de Dominio:** La aplicación de un modelo entrenado en PBMCs unicelulares hacia muestras independientes introduce incertidumbre técnica por efectos de lote.
- **Causalidad y Alcance Clínico:** El delta positivo en **CD274** refleja una asociación computacional y no debe interpretarse como prueba de causalidad biológica ni guía de decisión clínica.

5. Disponibilidad de Código y Artefactos

El código fuente, modelos serializados (`onco_target_random_forest.joblib`) y la aplicación interactiva desplegada en la nube mediante Streamlit Community Cloud [7] están consolidados en GitHub [8]:

<https://github.com/GarP23/onco-target-scrNA>

6. Bibliografía y Fuentes Consultadas

1. **10x Genomics Dataset Repository:** *3k PBMCs from a Healthy Donor (Single Cell Gene Expression)*. Disponible en: <https://www.10xgenomics.com/resources/datasets>
2. **European Nucleotide Archive (ENA):** *EMBL-EBI Public Genomics Repository & BioProject Search* (BioProject PRJEB108071). Disponible en: <https://www.ebi.ac.uk/ena/browser/view/PRJEB108071>
3. **NCBI Sequence Read Archive (SRA):** *National Center for Biotechnology Information Database*. Disponible en: <https://www.ncbi.nlm.nih.gov/sra>
4. **Wolf, F. A., Angerer, P., & Theis, F. J. (2018):** *SCANPY: large-scale single-cell gene expression data analysis*. *Genome Biology*, 19(1), 15. Disponible en: <https://scanpy.readthedocs.io/>
5. **Virshup, I., et al. (2021):** *anndata: Annotated data objects for single-cell genomics*. *bioRxiv / Python Package Documentation*. Disponible en: <https://anndata.readthedocs.io/>
6. **Pedregosa, F., et al. (2011):** *Scikit-learn: Machine Learning in Python*. *Journal of Machine Learning Research*, 12, 2825-2830. Disponible en: <https://scikit-learn.org/>
7. **Streamlit Documentation:** *Streamlit Cloud Deployment & Interactivity Framework*. Disponible en: <https://docs.streamlit.io/streamlit-community-cloud>
8. **GarP23 Repositorio Oficial GitHub:** *OncoTarget Mining Project (onco-target-scRNA)*. Disponible en: <https://github.com/GarP23/onco-target-scRNA>